



Análise Visual de Erros de Ponto Flutuante e das Units of Last Place em Experimentos Computacionais

Enzo Rocha Leite Diniz Ribas¹, D'Afonseca, L. A.², Rocha, L. M.³

Centro Federal de Educação Tecnológica de Minas Gerais, MG, Brasil

enzorochaleitedinizribas@gmail.com¹, luis.dafonseca@gmail.com², lucasmartinsrocha@gmail.com³

Resumo

Este trabalho investiga, por meio de experimentos computacionais, os efeitos da representação em ponto flutuante e das *Units in the Last Place* (ULP's). Foram analisadas funções matematicamente exatas cuja avaliação em aritmética de ponto flutuante produz erros de arredondamento, com ênfase nos efeitos associados à escala dos números representados e à resolução finita do sistema. Os experimentos foram implementados em Python e utilizados para gerar representações gráficas dos fenômenos observados. Os resultados evidenciam a influência da ULP na perda de significância e na alteração do comportamento numérico das funções avaliadas.

Palavras-Chave: Erros Numéricos; IEEE 754; Métodos Numéricos; Cancelamento Catastrófico; Ponto Flutuante.

Introdução

Frequentemente, computadores são utilizados para realizar cálculos numéricos repetitivos e de grande complexidade. Apesar disso, a representação computacional de números reais é limitada pela quantidade finita de bits disponível, fazendo com que operações aritméticas estejam sujeitas a erros de arredondamento. Essa limitação torna-se particularmente relevante à medida que a magnitude dos números aumenta, pois o espaçamento entre valores representáveis, ou *Unit in the Last Place* (ULP), também aumenta.

Neste trabalho, busca-se analisar experimentalmente a influência da representação em ponto flutuante e da ULP sobre o comportamento numérico de funções, investigando a relação entre a magnitude dos valores representados, os erros de arredondamento e a perda de significância. Para isso, são realizadas simulações computacionais e representações gráficas que permitem identificar e visualizar as regiões em que a aritmética de ponto flutuante produz resultados diferentes dos esperados pela aritmética exata.

Fundamentação Teórica

Um Sistema de Ponto Flutuante (SPF) é a maneira utilizada para aproximar números reais pelos computadores através de representações binárias compactas. Para a maioria dos computadores atuais, o padrão adotado é o definido pela IEEE-754 [?]. Definimos, então, a função $f_l(x)$ que leva um número real x a sua representação em ponto flutuante.

Devido à natureza discreta e finita dos SPF's, erros de representação são intrínsecos e propagam-se em operações aritméticas sucessivas, acumulando-se e podendo comprometer severamente a exatidão numérica das operações.

No padrão IEEE 754 um número de ponto flutuante é dividido em três partes. O primeiro bit, representa o **Sinal (S)** do número representado, indicando se o número é positivo ($S = 0$) ou negativo ($S = 1$); Os próximos N bits representam o **expoente (E)** com viés (bias), que é calculado como $\text{bias} = 2^{(N-1)} - 1$; E por fim, os últimos M bits Representam a **Mantissa (M)** que é parte fracionária significativa do número.

$$f_l(x) = (-1)^S \times (1.M) \times 2^{E-\text{bias}}, \quad (1)$$

Na mantissa, o termo $1.M$ indica que há um bit implícito “1” antes da mantissa nos números normalizados.

A *Unit of Last Place* (ULP) é a menor diferença entre dois números representáveis em ponto flutuante, ou seja, a distância entre um número e o próximo número representável [?, ?]. O conjunto de números exatamente representáveis se torna mais esparsos quanto mais distante o número for de zero, aumentando o erro relativo. Dessa forma, a ULP se torna uma medida relativa importante para avaliar a precisão dos cálculos realizados com ponto flutuante, podendo ser calculada como

$$\text{ULP}(x) = 2^{p-t+1}, \quad (2)$$

em que p é o expoente do número representado em ponto flutuante e t é o número de bits

da mantissa.

Desenvolvimento e Metodologia ou Materiais e Métodos

Para analisar o comportamento das ULP's, foram realizados experimentos computacionais utilizando funções da forma $g(x) = x^{10} + \ell - x^{10}$, cujo valor exato é constante e igual a ℓ . A implementação foi realizada utilizando a biblioteca *numpy* e outras bibliotecas para recursos gráficos para visualizar o comportamento numérico da função.

Pela natureza binária do sistema de ponto flutuante, analisar diferentes potências de base 2 para ℓ revela uma boa visualização da grandeza da $\text{ULP}(x)$ conforme x cresce.




Figura 2: Resultado da avaliação da função $f(x) = x^{10} + l - x^{10}$ num SPF IEEE de 64 bits para $\ell = 2^n, n \in \mathbb{N}, n \leq 7$. Fonte: Autor.

Ao avaliar g para diferentes valores de ℓ , usando ponto flutuante, obtemos o gráfico da $\text{ULP}(x)$, ilustrado na Figura ??, em que o valor esperado $g(x) = \ell$ é exibido apenas até um certo x , e a partir de um intervalo, a função assume o valor zero. Isso ocorre, pois o valor x^{10} é muito maior que ℓ , o que resulta na perda de significância, produzindo $x^{10} + \ell = x^{10}$. Entretanto, a ocorrência no intervalo intermediário ao valor esperado e o zero é observado uma oscilação relacionada surpreendente, que tem amplitude igual a $\text{ULP}(x^{10}) = \ell$.

Considere a função $f(x) = g(x)$ com $\ell = 1$. Ao avaliar f usando ponto flutuante, obtemos o gráfico da Figura ??, o intervalo intermediário de oscilação é aproximadamente $[49, 43]$.




Figura 3: Resultado da avaliação da função $f(x) = x^{10} + 1 - x^{10}$ num SPF IEEE de 64 bits. Fonte: Autor.

Resultados

Tomemos como exemplo, o valor $x = 42, 1$. Ao avaliar exatamente a expressão obtemos $x^{10} = 17.491.254.479.245.335, 8346502201$, porém como nosso SPF é limitado, x não tem representação exata, então a conta é feita com $f_l(x) \approx 42, 1000000000000001$. Com esse resultado realizamos a potenciação $A = f_l((f_l(x))^{10}) = 17.491.254.479.245.342$. Sua representação binária IEEE754 é dada por

S	E	M
0	10000110100	1111000100100001101000000100111101001010100000001111

Calculando a soma do literal, temos $B = A + 1 = 17.491.254.479.245.343$ porém, esse número não é representável, e precisa ser arredondado novamente, para um número representável, podendo ser o próximo ou o anterior. A norma IEEE754, define o critério

de representação como *Round to Nearest* e *Ties to Even*, ou seja, Arredondar para o mais perto, e em caso de empate, arredondar para o número cujo bit menos significativo (o mais à direita) é par ($LSB = 0$). Os dois possíveis canditos para representação são $A_2 = 010000110100111100010010000110100000010011110100101010000000\mathbf{0\ 1111}_2$ ou $010000110100111100010010000110100000010011110100101010000000\mathbf{1\ 0000}_2$ que é o valor correspondente a $(A + ULP(A))_2 = A + 2$. Como o bit mais a direita da segunda opção é 0, temos, $fl(B) = 17.491.254.479.245.\mathbf{344} = A + 2$. Resta subtrair o termo x^{10} , que já foi calculado anteriormente, então o resultado da operação é obtido da forma

$$\begin{aligned} fl(x^{10}) + fl(1) - fl(x^{10}) &= \\ 17.491.254.479.245.\mathbf{342} + fl(1) - fl(x^{10}) &= \\ 17.491.254.479.245.\mathbf{344} - fl(x^{10}) &= \\ 17.491.254.479.245.\mathbf{344} - 17.491.254.479.245.\mathbf{342} &= 2 \end{aligned}$$

Temos então, indícios de uma justificativa para a oscilação que ocorre nos intervalos intermediários.

Conclusões

Devem basear-se, exclusivamente, nos resultados do trabalho. Ressaltar se os objetivos expostos inicialmente foram cumpridos e se a hipótese foi confirmada. Aspectos me-

todológicos também devem ser abordados: dificuldades durante a pesquisa, resultados obtidos e qual o significado dos mesmos dentro da área de pesquisa. Quando possível, inserir outros tipos de estudos que poderiam ser feitos utilizando o mesmo tema e/ou outros aspectos a serem abordados a partir dos resultados apresentados.

Referências

[1] William Kahan. A logarithm too clever by half. *Unpublished note*, 2004.

[2] Jean-Michel Muller. On the definition of ulp(x). *CNRS – Laboratoire LIP, projet Arenaire*, 2005.

[3] Márcia Aparecida Gomes Ruggiero and Vera Lúcia da Rocha Lopes. *Cálculo numérico: aspectos teóricos e computacionais*. Pearson/Makron, Sao Paulo, 1998.

[4] IEEE Computer Society. *IEEE Standard for Floating-Point Arithmetic*, 2019.

Agradecimentos (Opcional)

Inserir, após as conclusões, de maneira sucinta os agradecimentos. Se o projeto for financiado por alguma agência de fomento, citar a fonte. Incluir a logomarca da sua universidade no lugar daquele modelo de logo no cabeçalho.